PROYECTO INTEGRADOR

Análisis Predictivo de la Empleabilidad y Salarios de los Docentes en México

De microdatos en crudo a modelos de Machine Learning

0.1 FUNDAMENTACIÓN

Planteamiento del Problema y Justificación

Problemática Real

Marcadas disparidades de ingreso y condiciones de precarización laboral en profesionales de la educación en México.

Evaluación de discrepancias entre horas laboradas y compensación real.

Justificación Analítica

Alta volumetría de microdatos censales exige un análisis capaz de garantizar inferencia estadística válida y representatividad nacional.

Superación de observaciones cualitativas mediante evidencia empírica.

0.2 Y 0.3 DIRECCIÓN ESTRATÉGICA

Objetivos e Hipótesis

OBJETIVO GENERAL

Modelar y predecir los ingresos salariales del docente en México

Identificando patrones sociodemográficos y laborales mediante algoritmos avanzados de evaluación cuantitativa.

PREMISA CENTRAL (HIPÓTESIS)

Escolaridad

Nivel académico alcanzado como predictor primario.

Jornada Laboral

Horas semanales efectivamente dedicadas.

Demografía

Sesgos sistemáticos de edad biológica y género.

1. PROCEDENCIA DE DATOS

Radiografía Oficial Institucional (ENOE)

Datos Crudos Originales

- **Volumen:** >300,000 registros poblacionales y más de 280 columnas.
- **Estructura:** 2 archivos separados (SDEMT y COE1T).
- **Calidad:** Espacios vacíos anómalos, nulos estadísticos y redundancias.

Dataset Refinado para ML

- **Volumen:** 6,433 educadores únicos (aislados vía código SINCO '23').
- **Dimensionalidad:** 20 columnas estrictamente analíticas.
- **Calidad:** 0 registros duplicados, nulos estandarizados, tipificación estricta.

2. LIMPIEZA Y PREPROCESAMIENTO

Arquitectura del Pipeline de Datos

1

Extracción

Múltiples cuestionarios CSV (Sociodemográfico y Empleo).

2

Aplanamiento

Fusión matricial 1:1 mediante seis llaves compuestas.

3

Integridad

Estandarización de nulos relacionales (\N) y eliminación de duplicados.

4

Normalización

Conversión de tipos y downcasting para optimizar memoria RAM.

3. IDENTIFICACIÓN Y CLASIFICACIÓN

Estructura de Variables

Variable Objetivo (Y)

ingocup (Ingreso Mensual)
Magnitud cuantitativa continua. Acepta nulos controlados.

Naturaleza del Problema
Regresión, predicción de montos exactos en MXN.

Predictores Aislados (X)

Sociodemográficas
Edad (eda), Sexo biológico (sex).

Capital Humano / Laborales
Escolaridad (cs_p13_1), Horas (hrsocup), Formalidad (p3a).

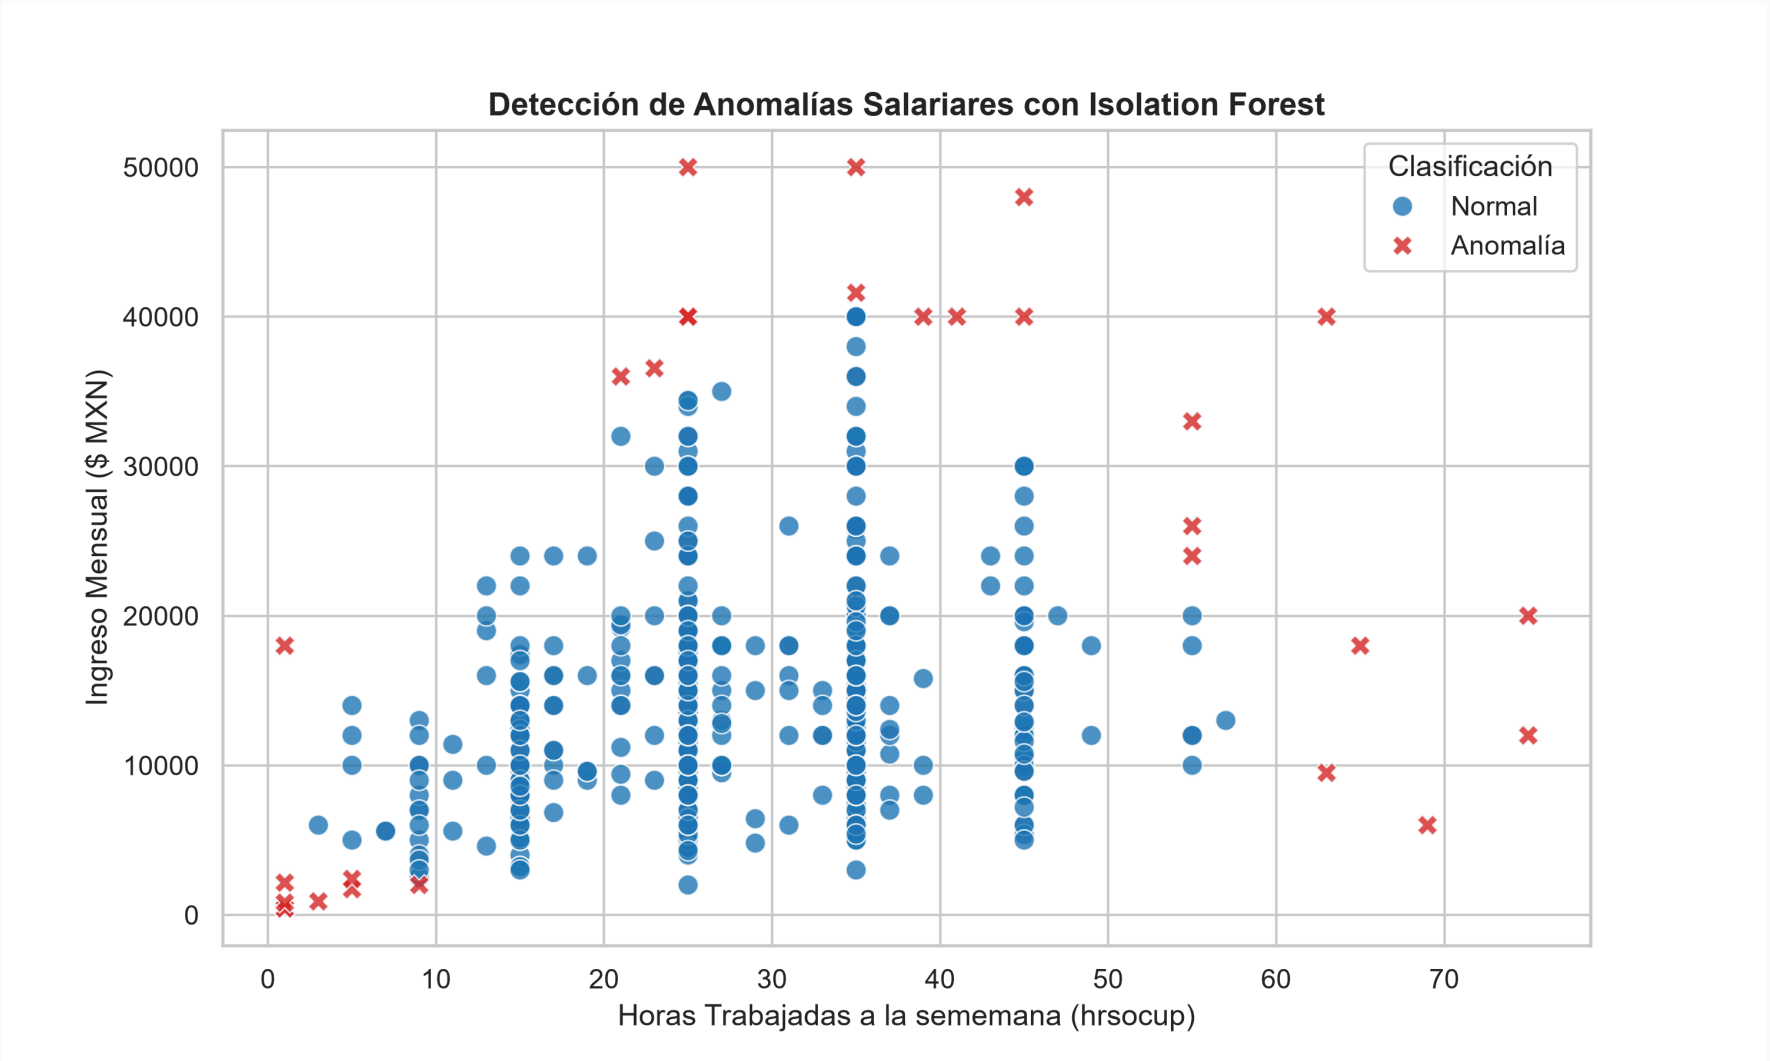
3.1 TRATAMIENTO DE OUTLIERS

Detección de Anomalías Salariales

Distribución original: Sesgada por sueldos atípicos irreales (ruido estadístico).

Isolation Forest: Algoritmo no supervisado aísla anomalías sin eliminar varianza legítima.

Depuración: Incrementa robustez del entrenamiento ML posterior.


Detección de Anomalías Salariares con Isolation Forest
Clasificación
Normal
Anomalía
Ingreso Mensual ($ MXN)
50000
40000
30000
20000
10000
0
0
10
20
30
40
50
60
70
Horas Trabajadas a la sememana (hrsocup)

4. MACHINE LEARNING

Modelos de Aprendizaje Automático

Regresión Lineal (Mincer)

Modelo baseline altamente interpretable. Coeficientes Beta directos para explicar magnitud de brechas.

Random Forest Regressor

Algoritmo de ensamble avanzado. Captura interacciones laborales complejas y relaciones no lineales.

Partición Estocástica

Hold-out estricto: 80% Entrenamiento (~5,146) y 20% Validación oculta (~1,287 registros).

5. ARQUITECTURA DE SOFTWARE

Estructura, Funcionamiento y Eficiencia

Stack Tecnológico

Lenguaje: Python en entornos Jupyter.

Librerías Core: Pandas (ETL), Scikit-Learn (Modelado ML).

Persistencia: Base de datos MySQL en contenedores Docker.

Carga y Eficiencia

Complejidad Base: Regresión Lineal O(N) asegura iteración rápida.

Carga Máxima: Random Forest Regressor incrementa complejidad temporal.

Optimización: Operaciones JOIN aplanadas reducen latencia en entrenamiento.

6. EVALUACIÓN DEL MODELO

Resultados y Rendimiento Analítico

0.23

Métrica R^2

Varianza salarial explicada por los determinantes seleccionados.

$3,493

Métrica MAE

Margen de error absoluto medio en pesos mexicanos.

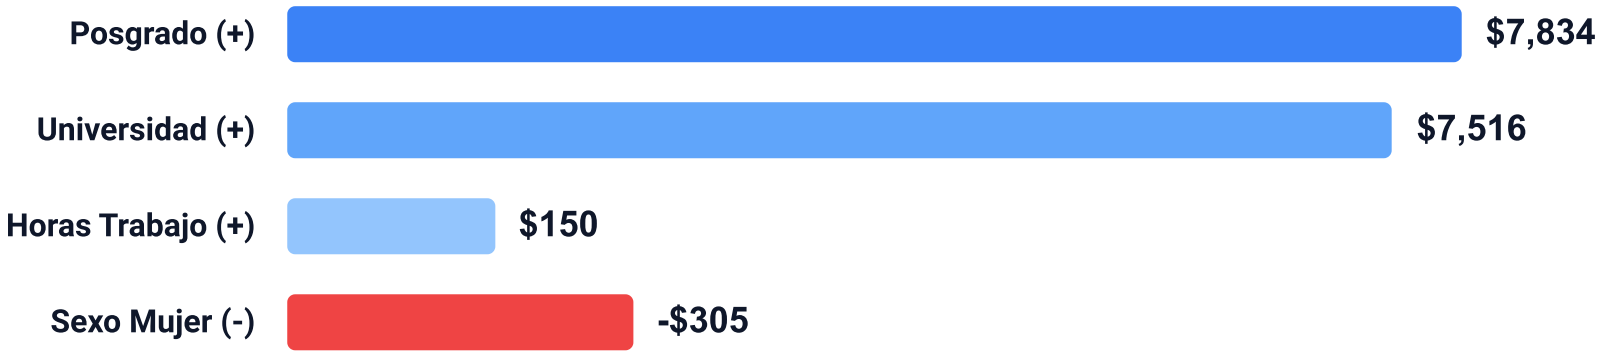
$4,646

Métrica RMSE

Raíz del error cuadrático, penaliza desviaciones severas.

6. INTERPRETACIÓN DE COEFICIENTES

Impacto Salarial por Variable



6. CONCLUSIONES

Síntesis de Hallazgos

Desconexión Horas-Ingreso (Hipótesis confirmada)

La carga horaria no garantiza equidad. Variables latentes como el género penalizan sistemáticamente el salario base.

Limitaciones Analíticas

Varianza extrema del mercado formal vs informal exige modelos no lineales para superar el R^2 actual.

Aportación y Trabajo Futuro

Base empírica auditable para políticas públicas. Siguiente etapa: Automatización trimestral (Observatorio).