UNIVERSIDAD DE GUADALAJARA (CUGDL) • PROYECTO INTEGRADOR

Presentación Preliminar

# Análisis Predictivo y Determinantes Salariales del Sector Docente en México

Evaluación de condiciones laborales y modelado de ingresos mediante microdatos oficiales de la ENOE.

EQUIPO DE INVESTIGACIÓN

**González, Hernández, Martínez, Patiño**

0.1 FUNDAMENTACIÓN DEL PROYECTO

# Planteamiento del Problema Real y Justificación

## Problemática Real

**Brechas salariales e inequidad:** Existen marcadas disparidades de ingreso y condiciones de precarización laboral en profesionales de la educación en México.

Evaluación de discrepancias entre horas laboradas y compensación real.

## Justificación Analítica

**Análisis Masivo de Datos:** La alta volumetría de microdatos censales exige un pipeline algorítmico capaz de garantizar inferencia estadística válida y representatividad nacional.

Superación de observaciones cualitativas mediante evidencia empírica.

0.2 & 0.3 ESTRATEGIA DEL TRABAJO

# Objetivos e Hipótesis de Investigación

OBJETIVO GENERAL

## Modelar y predecir los determinantes del ingreso salarial docente en México

Identificando patrones sociodemográficos y laborales mediante algoritmos avanzados de evaluación cuantitativa.

PREMISA CENTRAL (HIPÓTESIS)

**Escolaridad**
Nivel académico alcanzado como predictor primario.

**Jornada Laboral**
Horas semanales efectivamente dedicadas.

**Demografía**
Sesgos sistemáticos de edad biológica y género.

1. ADQUISICIÓN Y PROCEDENCIA

# Fuente Oficial y Muestra de Estudio

**6,602**

## Registros Individuales

Aislamiento estricto de profesionales de la educación mediante el Código SINCO 23.

Muestreo robusto que previene el sobreajuste (overfitting) en Machine Learning.

### Origen Oficial INEGI

Microdatos trimestrales de la Encuesta Nacional de Ocupación y Empleo (ENOE).

### Sin Fuentes Secundarias

Extracción directa omitiendo plataformas externas o informales como Kaggle.

### Integración de Módulos

Cruce relacional exitoso entre los cuestionarios SDEMT y COE1T del INEGI.

2. LIMPIEZA Y PREPROCESAMIENTO

# Flujo de Limpieza y Transformación (ETL)

1

### Extracción RAW

Descarga directa de 5 archivos CSV estructurados del INEGI.

2

### Unión Relacional

INNER JOIN mediante llaves compuestas de vivienda y hogar.

3

### Filtrado Docente

Aislamiento estricto de la rama ocupacional SINCO 23.

4

### Selección Features

Reducción drástica de 280 a 20 columnas clave para ML.

3. CLASIFICACIÓN DE VARIABLES

# Variables Seleccionadas para el Modelo

| Rol | Campo ENOE | Tipo de Dato | Descripción Operativa |
|---|---|---|---|
| **Objetivo (y)** | `ingocup` | Cuantitativo continuo | Ingreso mensual reportado ($ MXN). |
| **Predictor (X1)** | `hrsocup` | Cuantitativo discreto | Horas trabajadas por semana. |
| **Predictor (X2)** | `cs_p13_1` | Categórico ordinal | Nivel máximo de escolaridad. |
| **Predictor (X3)** | `eda / sex` | Numérico / Categórico | Edad biológica y género reportado. |
| **Predictor (X4)** | `p3a` | Categórico nominal | Condición de formalidad laboral. |

# Estrategia de Aprendizaje Automático (ML)

## Tipo de Problema

**Supervisado - Regresión Múltiple**

- Predicción continua del valor del salario mensual.
- Análisis simultáneo de múltiples predictores.

## Control Metodológico

**Prevención del Sobreajuste**

- Tamaño muestral óptimo ($n=6,602$).
- Minimización del riesgo de overfitting.

5. INFRAESTRUCTURA Y EFICIENCIA ALGORÍTMICA

# Arquitectura del Código y Complejidad Computacional

## Stack Tecnológico

**Python & Jupyter:** Entorno base analítico.

**Pandas & NumPy:** Operaciones matriciales.

**Docker & MySQL:** Persistencia relacional.

Contenedor aislado en puerto 3307.

## Desnormalización

Se desnormalizó la base a un DataFrame aplanado (`df_docentes`) para evitar JOINs continuos en tiempo de ejecución.

**Reducción drástica de latencia computacional.**

## Complejidad Temporal

**ETL en Pandas:** $O(n)$ tiempo lineal.

**Carga Masiva SQL:** `LOAD DATA` previene overhead $O(n \times m)$.

**Indexación B-Tree:** $O(\log n)$ en validación de llave primaria.

Optimización de memoria con TINYINT y DECIMAL.

6. RESULTADOS E INFERENCIA INICIAL

# Métricas Descriptivas Consolidadas en SGBD

| 6,433 | $15,233.60 | 25.6 hrs |
| --- | --- | --- |
| Docentes Consolidados | Salario Promedio Mensual ($ MXN) | Promedio Horas Semanales |

**Salario Máximo Observado**
**$120,000.00 MXN**

**Salario Mínimo Observado**
**$200.00 MXN**

6. RESULTADOS, INTERPRETACIÓN Y CONCLUSIONES

# Aportación y Valor del Proyecto

### Toma de Decisiones

Transformación de datos crudos en información fundamentada para políticas públicas.

### Evidencia Empírica

Sustento cuantitativo riguroso sobre la realidad laboral del educador en México.

### Reproducibilidad

Código legible y estructurado en GitHub/Jupyter para auditorías o consultas futuras.

### Modelo Relacional

Integración sólida de esquemas y llaves compuestas en SGBD local mediante Docker.

6. FASES FUTURAS DEL PROYECTO

# Próximos Pasos de Implementación

PASO 01

### Entrenamiento de Modelos

Ejecución de regresiones lineales y múltiples en Python con Scikit-Learn.

PASO 02

### Evaluación de Métricas

Cálculo de $R^2$, RMSE y análisis minucioso de residuos de predicción.

PASO 03

### Persistencia SGBD

Implementación final de esquemas y llaves primarias en MySQL / PostgreSQL.

PROYECTO INTEGRADOR

# ¡Gracias por su Atención!

Espacio abierto para preguntas, retroalimentación y defensa metodológica.

Universidad de Guadalajara • CUGDL