

UNIVERSIDAD DE GUADALAJARA

Red Universitaria e Institución Benemérita de Jalisco



Alumnos: González Martínez Fernanda Aurora Samantha
Hernández Hernández Jose Pablo
Martínez Belmonte Hoshi Esmeralda
Patiño Casatrillon Johan David

BASES DE DATOS

PROYECTO FINAL

Análisis predictivo y estadístico de la empleabilidad y determinantes salariales del sector docente en México

- Nombre y descripción detallada de la fuente de datos seleccionada:
  Microdatos de la Encuesta Nacional de Ocupación y Empleo (ENOE), elaborada y publicada por el Instituto Nacional de Estadística y Geografía (INEGI).
  La ENOE es el principal instrumento estadístico del gobierno mexicano para evaluar el mercado laboral. El conjunto de datos seleccionado integra registros a nivel individual (microdatos) recabados durante el levantamiento trimestral. Al descargar el paquete original de microdatos del INEGI, la fuente se compone de cinco archivos CSV (separados por comas):
  - ENOE_SDEMT226 (Cuestionario Sociodemográfico): Proporciona características de la población como edad, sexo, nivel de escolaridad y entidad federativa.
  - ENOE_COE1T226 (Cuestionario de Ocupación y Empleo 1): Contiene variables laborales críticas como ingresos mensuales, horas trabajadas a la semana, sector de actividad y el código del Sistema Nacional de Clasificación de Ocupaciones (SINCO).
  - ENOE_COE2T226 (Cuestionario de Ocupación y Empleo 2): Complementa la información laboral con detalles adicionales sobre las condiciones de trabajo.
  - ENOE_HOGT226 (Cuestionario de Hogares): Detalla la composición y características generales de los hogares encuestados.
  - ENOE_VIVT226 (Cuestionario de Vivienda): Describe las condiciones de infraestructura y servicios de las viviendas.

  Para conformar la base de datos central de este proyecto, se unificaron las tablas principales (SDEMT y COE1T) mediante llaves de identificación únicas. Tras el cruce y procesamiento de los datos en crudo, se logró aislar una muestra depurada de 6,602 registros que corresponden estrictamente a profesionales de la educación (identificados mediante los códigos SINCO que inician con '23', abarcando docentes de nivel preescolar, primaria, secundaria y superior).

- Justificación de su uso: ¿Por qué esta fuente es adecuada y relevante para su proyecto integrador?
  Relevancia analítica y social: Aborda una problemática real, institucional y de alto impacto público (las condiciones laborales y brechas salariales de la comunidad docente), evaluando las condiciones del sector educativo mexicano.
  Validez oficial: Al provenir directamente del INEGI, los datos garantizan representatividad nacional, cumpliendo con un muestreo grande para el uso de predicciones y probabilidades, además de que aportan una total validez científica
  Integración multidisciplinaria:
  - La base depurada de 6,602 educadores posee la solidez estadística necesaria para realizar pruebas de hipótesis paramétricas y entrenar modelos de *Machine Learning* (como regresiones múltiples) minimizando el riesgo de sobreajuste.

- Su estructura masiva inicial requiere procesos formales de limpieza, transformación e ingesta relacional, justificando su implementación técnica.

- Herramienta utilizada por la fuente (especificar la tecnología o formato de origen): La fuente original distribuye los datos mediante cinco archivos CSV estructurados, provistos por un organismo gubernamental oficial (INEGI) para su descarga libre.
  Para la etapa de extracción y preprocesamiento, se utilizó el lenguaje Python (a través de las bibliotecas pandas y numpy en entornos Jupyter). Como parte del desarrollo para la materia, estos datos procesados serán persistidos e implementados en un Sistema de Gestión de Bases de Datos local, administrando los esquemas, relaciones y consultas mediante el usuario root del sistema.

- Tipo de datos que contiene su fuente de datos: La información extraída de los microdatos de la Encuesta Nacional de Ocupación y Empleo (ENOE) es de naturaleza estructurada. Los datos provienen de archivos de texto plano separados por comas (CSV) que se organizan de forma tabular tradicional, donde cada fila representa el registro de un individuo encuestado y cada columna representa una variable específica de los cuestionarios oficiales.
  En cuanto a su naturaleza interna, la base de datos depurada para el sector docente contiene principalmente:

  - Datos Numéricos: Valores cuantitativos tanto continuos como discretos. Ejemplos críticos para nuestro proyecto son el ingreso salarial mensual, las horas trabajadas a la semana y la edad del encuestado.
  - Datos Categóricos (nominales y ordinales): Variables cualitativas codificadas numéricamente por el INEGI. Ejemplos fundamentales son el nivel de escolaridad, el sexo, la entidad federativa y los códigos del Sistema Nacional de Clasificación de Ocupaciones (SINCO, la rama '23' para educadores).

  Cabe aclarar que originalmente la base de datos contenia unas 280 columnas pero tras la unión de los cuestionarios en crudo, se aplicó un proceso de selección de características orientado exclusivamente al objetivo del proyecto. Se descartaron variables que introducen ruido estadístico o que son irrelevantes para el fenómeno docente (como características de los materiales de la vivienda, módulos de migración o subsidios agrícolas). La selección final del listado preliminar se justifica bajo tres criterios técnicos:

  1. Variables de Aislamiento y Objetivo (Target): Se conservó el campo p3 (ocupación) ya que es el filtro estructural para aislar la muestra a los docentes (códigos 23). Asimismo, ingocup es el eje de la investigación al fungir como nuestra variable dependiente objetivo (y) para los modelos predictivos.

  2. Determinantes Salariales (Predictores o Features): Se seleccionaron únicamente los factores sociodemográficos (eda, sex, cs_p13_1) y laborales (hrsocup, p3a) que la literatura económica dicta como variables independientes críticas que explican la varianza en los sueldos y la brecha de empleabilidad.

3. Integridad Relacional para la Base de Datos: Los campos geográficos y de control (cve_ent, con, n_hog, n_ren) se preservaron para servir como llaves primarias compuestas y llaves foráneas, lo que permitirá normalizar las tablas y diseñar el modelo Entidad-Relación en el sistema de gestión de bases de datos local.

- Borrador/Listado preliminar: A partir de la exploración del dataset unificado y filtrado (6,602 registros de educadores), se hace el primer inventario de los campos o columnas principales detectados que usaran en el proyecto:

Agrupación	Columnas / Campos Detectados
Identificadores de Cruce (Llaves)	cve_ent, con, v_sel, n_hog, h_mud, n_ren, r_def, upm, d_sem
Atributos Sociodemográficos	eda (Edad), sex (Sexo), cs_p13_1 (Nivel escolaridad), cs_p13_2 (Grado escolaridad)
Métricas Laborales y Salariales	ingocup (Ingreso mensual), hrsocup (Horas trabajadas), p3 (Código de ocupación SINCO)
Condiciones del Empleo	p3a (Formalidad/Contrato), p3c1, p3c2, p3c3 (Características de la institución)

- Diccionario de datos:

Categoría / Campo	Tipo de dato	Restricción / Dominio	Descripción
cve_ent	TINYINT	PK, NOT NULL, CHECK (1-32)	Clave de la entidad federativa (del 1 al 32). Forma parte de la llave compuesta.
con	INT	PK, NOT NULL	Número de control de la vivienda. Llave estructural primaria.
v_sel	TINYINT	PK, NOT NULL	Identificador de la vivienda seleccionada. Llave estructural.
n_hog	TINYINT	PK, NOT NULL	Número de hogar dentro de la vivienda. Llave estructural.
h_mud	TINYINT	PK, NOT NULL	Identificador de hogar mudado (0 = No, 1 = Sí). Llave estructural.
n_ren	TINYINT	PK, NOT NULL	Número de renglón (identificador individual del residente). Llave estructural.
upm	INT	NOT NULL	Unidad Primaria de Muestreo. Identificador geográfico/estadístico.

d_sem	TINYINT	NOT NULL, CHECK (1-7)	Día de la semana de la entrevista.
r_def	TINYINT	NOT NULL, CHECK (0-99)	Resultado definitivo de la entrevista (código de éxito/fracaso del levantamiento).
eda	TINYINT	NOT NULL, CHECK (>= 15)	Edad del docente en años cumplidos (restringido a la Población Económicamente Activa).
sex	TINYINT	NOT NULL, CHECK (1, 2)	Sexo biológico del encuestado (1 = Hombre, 2 = Mujer).
cs_p13_1	TINYINT	NOT NULL, CHECK (0-99)	Nivel máximo de escolaridad aprobado (catálogo INEGI).
cs_p13_2	TINYINT	NOT NULL	Grado escolar o año específico aprobado dentro del nivel de escolaridad reportado.
p3	VARCHAR(4)	NOT NULL, LIKE '23%'	Código de ocupación principal (SINCO). Aislado estrictamente a profesionales de la educación (inicia con '23').
Ingocup	DECIMAL(10,2)	NULL	Ingreso mensual. Acepta NULL ya que existen encuestados que se niegan a declarar su salario. (Variable Objetivo).
Hrsocup	TINYINT	NULL, CHECK (>= 0)	Horas trabajadas a la semana.
p3a	TINYINT	NULL	Condición de formalidad de empleo (tipo de contrato y prestaciones de ley).
p3c1	TINYINT	NULL	Tipo de institución educativa (pública, privada, etc.).
p3c2	TINYINT	NULL	Tipo de local o espacio físico donde se desempeña el trabajo.
p3c3	TINYINT	NULL	Tamaño del establecimiento (rango del número de empleados en la institución).

- Definición de relaciones entre fuentes/tablas: Para la construcción de la base de datos, se consumen y conectan dos fuentes tabulares principales provenientes de los microdatos del INEGI:

1. Tabla Sociodemográfica (ENOE_SDEMT): Entidad que almacena los atributos personales y educativos de la población.
2. Tabla de Ocupación y Empleo (ENOE_COE1T): Entidad que almacena las características laborales, salariales e institucionales.

Ambas tablas operan bajo un modelo relacional y se conectan entre sí mediante una Llave Primaria/Foránea Compuesta. Dado que la ENOE no provee un ID único de persona, la relación se establece mapeando exactamente los mismos identificadores estructurales, geográficos y de vivienda en ambas entidades: cve_ent, con, v_sel, n_hog, h_mud y n_ren.

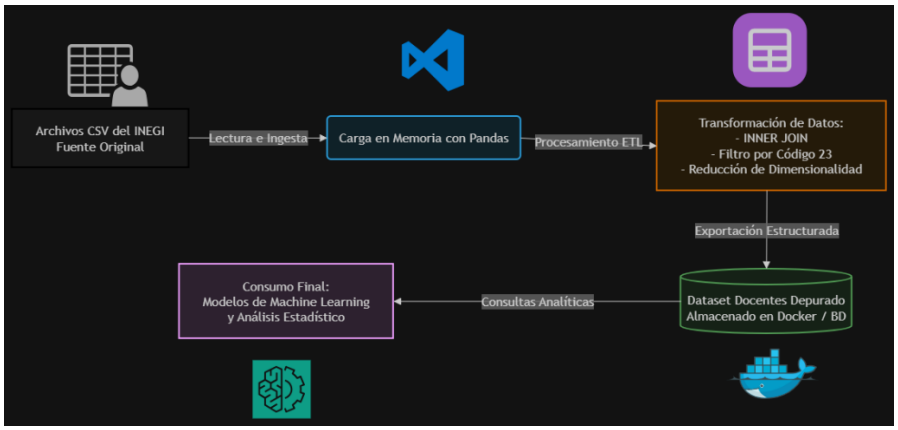
- Tipo de cardinalidad: La cardinalidad original entre la entidad SDEMT y la entidad COE1T es de 1:1 (Uno a Uno).

Justificación según el modelo de datos: Por el diseño del INEGI para un levantamiento trimestral, cada registro sociodemográfico genera un único cuestionario de ocupación principal. Es decir, un individuo en la tabla sociodemográfica tiene un, y solo un, registro laboral correspondiente en esa misma ronda de encuestas. No existen múltiples perfiles laborales principales para la misma persona en el mismo trimestre.

Justificación técnica de la estructura única: Aunque el origen relacional es de dos tablas (1:1), el flujo de datos culminó en la consolidación de un archivo plano o estructura única (Data Frame df_docentes) mediante un proceso INNER JOIN.

Esta consolidación en una sola tabla desnormalizada se justifica técnicamente por la naturaleza de las otras materias (como Machine Learning) que requieren matrices bidimensionales continuas para el desarrollo del proyecto. Mantener los datos normalizados en múltiples tablas durante el consumo final exigiría operaciones de cruce (JOIN) en tiempo de ejecución, lo cual incrementaría el costo computacional durante el entrenamiento d los modelos. Por ello, el modelo físico local operará con esta estructura aplanada, optimizando las consultas analíticas.

- Diagrama visual del flujo de datos:



- Explicación narrativa del diagrama de flujo de datos:

La arquitectura de datos de este proyecto integrador sigue un flujo secuencial lineal tipo ETL (Extracción, Transformación y Carga), diseñado para transicionar desde microdatos gubernamentales crudos hasta matrices optimizadas para un entrenamiento. A continuación se describe cada nodo tecnológico del flujo:

1. Origen de los Datos (archivos CSV del INEGI): El flujo inicia en el repositorio oficial del INEGI, desde donde se descargan los microdatos trimestrales de la Encuesta Nacional de Ocupación y Empleo (ENOE) en formato de valores separados por comas (.csv). En esta etapa, los datos se encuentran en bruto, abarcando a toda la población encuestada y distribuidos en múltiples tablas (Sociodemográfico y Empleo).

2. Extracción e Ingesta (Entorno Python): Los archivos CSV se alojan en un directorio local (/data) y son leídos mediante la librería pandas en un entorno interactivo de Jupyter Notebook, ejecutado sobre Visual Studio Code. En este nodo, los datos en disco se cargan en la memoria RAM como estructuras bidimensionales de datos (DataFrames).

3. Procesamiento y Transformación (Limpieza y Filtro): Es el nodo computacional de mayor peso. Aquí ocurren tres procesos técnicos utilizando el lenguaje Python:

- Fusión Relacional (Join): Se unifican los DataFrames SDEMT y COE1T utilizando una llave primaria compuesta (cve_ent, con, v_sel, n_hog, h_mud, n_ren).
- Filtrado Poblacional: Se aísla el objeto de estudio mediante una expresión de búsqueda de cadenas ('23' en el campo p3), reteniendo exclusivamente a los 6,602 profesionales de la educación.
- Reducción de Dimensionalidad: Se eliminan más de 250 columnas innecesarias y se conservan únicamente los 20 determinantes sociodemográficos y salariales listados en el diccionario de datos.

4. Almacenamiento Local (contenedor de base de datos): El dataset de docentes limpio y procesado es exportado e ingestado de manera persistente en un sistema de gestión de bases de datos local, el cual se encuentra virtualizado y aislado mediante un contenedor de Docker. La administración del esquema relacional y la seguridad se gestiona mediante las credenciales de usuario root. Este nodo garantiza que la información esté disponible y estructurada (con sus tipos de datos correctos como TINYINT o DECIMAL) sin tener que volver a procesar los CSV originales.

5. Consumo Final (análisis): En el último nodo del ciclo de vida del dato, el motor de base de datos sirve la información estructurada a los módulos de análisis. Por un lado, los datos son consumidos por algoritmos de Machine Learning (librerías como scikit-learn) para entrenar modelos predictivos. De forma paralela, son consumidos para realizar pruebas de hipótesis.

- Conclusión: Reflexión Analítica

La importancia del almacenamiento estructurado para generar información útil en Inteligencia Artificial: El desarrollo de modelos predictivos y algoritmos de Inteligencia Artificial depende enteramente de la pureza, consistencia y representatividad de los datos que los alimentan. A lo largo de este proyecto, se demostró concretamente que los microdatos crudos (los archivos CSV originales de la ENOE con cientos de variables) contienen ruido estadístico, nulos anómalos, identificadores duplicados y errores de formato. El almacenamiento estructurado, gestionado a través de un motor relacional como MySQL alojado en Docker, actúa como el principal filtro de control de calidad. Al definir una tabla desnormalizada con tipos de datos precisos y llaves primarias compuestas, el sistema de bases de datos garantizó la eliminación de registros corruptos (duplicado) y la preservación de nulos reales estadísticos (\N). Sin esta base estructurada, los futuros modelos de Machine Learning este ruido, teniendo como resultados completamente sesgados.

La relevancia de la materia de bases de datos para el área de Ciencia de Datos e IA: La Ciencia de Datos y la Inteligencia Artificial no pueden operar en el vacío analítico ni depender exclusivamente del procesamiento en memoria RAM (como los DataFrames de Pandas), ya que en entornos empresariales y gubernamentales reales la cantidad de información es masiva. La materia de bases de datos nos provee los conocimientos para que en un futuro podamos garantizar la persistencia de la información, la optimización espacial y la eficiencia en el consumo de los datos, así mismo saber que entornos utilizar para cada situación o problema establecido. Aprender a administrar la cardinalidad (relaciones 1:1, entre otras) y orquestar cargas masivas de información minimiza la latencia computacional y acelera los tiempos de entrenamiento en etapas posteriores, o en muchos casos la busqueda especializadda de ciertos datos. En resumen, la materia de bases de datos son el principio de la Inteligencia Artificial; sin una gobernanza de datos relacional y eficiente, la extracción de conocimiento y la inferencia predictiva son técnica y computacionalmente inviables.

- Uso de IA en la elaboración del documento (Declaración Transparente)

Para el desarrollo metodológico, estructuración y ejecución técnica de este proyecto integrador, el equipo hizo uso de Inteligencia Artificial generativa estrictamente como una herramienta de apoyo analítico y copiloto de programación, bajo las siguientes aplicaciones específicas:

1. Limpeza de datos y errores en docker: Se utilizó IA para optimizar la sintaxis de limpieza en Python, específicamente en la formulación de expresiones regulares (regex) para la conversión al estándar relacional (\N). Adicionalmente, sirvió como soporte de debugging interactivo para diagnosticar y solucionar errores de entorno en Docker y excepciones de compatibilidad de tipos (modo estricto) durante las ingestas LOAD DATA INFILE en MySQL.

2. Estructuración y redacción de entregables: Se empleó la IA para estructurar el Diccionario de Datos del proyecto y revisar la cohesión narrativa, ortografía y estilo académico del reporte, asegurando que tuvieran un rigor profesional.

Nota de integridad del equipo: Todas las decisiones estructurales (selección de la muestra, elección de las variables de estudio, preservación de nulos y exclusión de imputaciones por mediana) fueron auditadas, validadas y dirigidas de manera crítica por los miembros del equipo.

REFERENCES

- Instituto Nacional de Estadística y Geografía (INEGI). (2024). Microdatos de la Encuesta Nacional de Ocupación y Empleo (ENOE). Archivos consultados: Cuestionario Sociodemográfico (SDEMT) y Cuestionario de Ocupación y Empleo 1 (COE1T). Recuperado de los repositorios oficiales del INEGI.
- Instituto Nacional de Estadística y Geografía (INEGI). (2019). *Sistema Nacional de Clasificación de Ocupaciones (SINCO).* (Rama '23' utilizada para el filtrado de la muestra docente.
- The pandas development team. (2024). *pandas-dev/pandas: Pandas* (Software para la manipulación y análisis de datos en la extracción ETL).
- Oracle Corporation. (2024). *MySQL 8.0 Reference Manual.* (Documentación técnica para la estructuración DDL, llaves compuestas e instrucciones de carga masiva relacional).